


CUP IT 2025

Трек: Анализ данных

Fullstack Excel

Сабанцева Александра
Богодист Всеволод
Игитов Максим
Якимов Роман
Вичук Артем



ПРОБЛЕМА

Страховая компания сталкивается с необходимостью точного планирования финансовых потоков, но существующие методы прогнозирования выплат обладают **ключевыми ограничениями**:



Ограниченный объем данных (глубина всего 2 года)



Ярко выраженная сезонность выплат, не учитываемая текущими моделями



Низкая точность долгосрочных прогнозов (на год вперед)



Отсутствие адаптации к изменяющимся внешним условиям

РЕШЕНИЕ

Разработана **интеллектуальная система прогнозирования**, сочетающая:

01 Композитная линейная модель для прогнозирования на выборке из 2х лет

- Выделение тренда + сезонные компоненты
- Работает на 24 точках, прозрачна, быстро внедряется

02 Автоматизированный Prophet

- Сам выявляет тренды, сезонности (неделя/год) и аномалии
- Работает "из коробки", масштабируется на все продукты

Сейчас - линейная композиция (данных мало)
Через 1-2 года → Переход на Prophet

ЭФФЕКТ




Относительная ошибка прогноза менее 5%



Возможность как краткосрочного (месячного), так и **долгосрочного (годового) планирования**



Оптимизация резервирования средств



Снижение издержек за счет полной автоматизации процесса прогнозирования страховых выплат

Особенности страховых выплат способствуют сезонности в их начислении.

Алгоритм, способный предсказывать сезонность, позволит лучше управлять финансовыми потоками при планировании.


Страховая выплата

это денежная сумма, установленная законом и/или условиями договора, которую страховщик обязан выплатить при наступлении страхового случая [1].

Страховые выплаты начисляются когда:

-  1. Случай является страховым и прописан в страховом договоре;
-  2. Запрос на выплату был подан в сроки, прописанные в страховом договоре;
-  3. Клиент предоставил актуальные данные при заключении договора;
-  4. Клиент не пытался фальсифицировать страховой случай;
-  5. Клиент обратился в одно из мед. учреждений, указанных в страховом договоре;
-  6. Клиент соблюдал все указания касательно режима лечения.

Страховой продукт формирует резервы для осуществления выплат.



Для повышения эффективности использования этих средств необходимо разработать алгоритм, способный с высокой точностью прогнозировать данные о выплатах на временном ряду предстоящего года.

Анализ данных показал, что прогнозируемая величина платежей за месяц получается путем агрегации отдельных платежей. Категориальные признаки позволяют разбивать временной ряд на составляющие.

Таргет (прогнозируемая величина):
агрегированные платежи за месяц

Что необходимо для решения задачи:
Агрегировать данные по месяцам

Особенности данных:

1. **Распределение выплат по договорам - лог. нормальное (есть выбросы)**
НО: при агрегации выбросы тоже агрегируются - зачем отбрасывать большие платежи для "нормальности" данных?
НО: агрегация через "средний" платеж бессмысленно из-за нестабильности сред
2. **Четкая сезонность и тренд при агрегации средних выплат;**
3. **Нестабильность категориальных фичей.**

Задача в терминах ML:

прогнозирование (регрессия) временного ряда агрегированных платежей Сберстрахования

Что представляют данные:

Набор из отдельных выплат по всем сервисам и клиентам сбера

Варианты агрегации таргета:

1. Число уникальных сервисов (по service_code) и **средние выплаты сервиса за месяц;**
2. Число уникальных клиентов (по patient_id) и **выплаты на клиента за месяц;**
3. Число выплат (по service_document_id) и средние выплаты по договору.
4. Самое простое: **общие выплаты за месяц.**

Модель хорошо себя показывает, выявляет сезонность, но "не уверена в прогнозах" - для лучшего результата нужна большая выборка.

SARIMA

Используем стандартную модель SARIMA с трендами и сезонностью, объединяющую как несезонные и сезонные параметры:

- 01 авторегрессию
- 02 дифференцирование
- 03 скользящее среднее

Она устраняет нестационарность через дифференцирование и моделирует автокорреляцию через лаги и ошибки.

Предобработка

- 01 Агрегация выплат по месяцам;
- 02 Ряд не стационарен из-за тренда - не нужны преобразования.

Гиперпараметры

- 01 Подбор через генетический алгоритм (Optuna);
- 02 MAPE на отложенных 3 месяцах - критерий.


Метрики

MAE: 2.052.676 руб.

Тест Льюнга-Бокса: 12.47, p-value: 0.41

MAPE: 1.65%

Нет автокорреляции остатков



Модель хорошо себя показывает, выявляет сезонность, но является слишком "тяжеловесой" (особенно учитывая, что у нас лишь 24 точки для обучения).

PROPHET

Модель Prophet, разработанную для прогнозирования временных рядов с сезонностью, праздничными эффектами и нелинейными трендами, объединяющую адаптивные компоненты:

01 тренда

02 периодичности (суточные, недельные, годовые)

03 внешние события

Она автоматически учитывает нестационарность через гибкое моделирование изменений тренда и сезонности.

Предобработка

01 Агрегация выплат по месяцам;

02 Ряд не стационарен из-за тренда - не нужны преобразования.

Гиперпараметры

01 Подбор через генетический алгоритм (Optuna);


02 MAPE на отложенных 3 месяцах - критерий.

Метрики

MAE: **2.903.792** руб. Тест Льюнга-Бокса: **12.48**, p-value: **0.41**

MAPE: **2.29%**

Нет автокорреляции остатков



ГИПОТЕЗА НЕ ОПРАВДАЛАСЬ


1. Слишком много признаков относительно данных — модель переобучается, запоминая шум вместо закономерностей.
2. Лаги "съедают" и без того маленькую выборку данных — после создания lag_12 и lag_24 полезных наблюдений почти не остается.

ГРАДИЕНТНЫЙ БУСТИНГ

Использование градиентного бустинга с лагами повышает точность прогнозирования временных рядов за счёт автоматического учёта временных зависимостей:

- 01 лаг-эффекты
- 02 сезонность
- 03 тренд
- и интеграции дополнительных статистических признаков:
- 01 скользящие средние
- 02 волатильность

При этом сохраняет простоту в вычислениях.



Предобработка

- 01 Агрегация по месяцам
- 02 Фичи на основе временных рядов

- Скользящие статистики: среднее и стандартное отклонение за 3 и 12 месяцев.
- Разности и % изменения
- Лаги: сдвиги целевой переменной на 1, 2, 3, 6, 9, 12, 24 месяца.

03 Временные и сезонные фичи

- Месяц, год, квартал, дни в месяце, флаги начала/конца месяца.
- Тригонометрические фичи для учета сезонности.

04 Дополнительные методы сглаживания

- Экспоненциальное сглаживание.
- Декомпозиция ряда (тренд, сезонность, остатки) и автокорреляция (ACF).

Метрики

MAE: 4559198.72 руб.

MAPE: 7.61%



ГИПОТЕЗА НЕ ОПРАВДАЛАСЬ

1. Сглаживание данных (логарифмирование + нормализация) привело к потере важных особенностей временного ряд.
2. Прогнозирование на 52 недели путём автогенерации значений усугубил проблему накопления ошибки.
3. Данных агрегированных по месяцам недостаточно для обучения.

ISTM

Использование LSTM-модели для предсказания сумм выплат по неделям позволит учесть:

- 01 временные зависимости
- 02 тренды в данных

Логарифмирование выплат и нормализация данных помогут сгладить резкие колебания, а архитектура модели с несколькими слоями LSTM обеспечит точность прогнозирования.



Предобработка

- 01 Удаление строк с пропущенными значениями.
- 02 Агрегация данных по неделям (сумма выплат за неделю).
- 03 Фильтрация значений (исключение нулевых выплат).
- 04 Логарифмирование выплат ($\text{np.log}(\text{total_payments})$).
- 05 Масштабирование данных (MinMaxScaler).
- 06 Создание последовательностей длиной 12 недель для обучения модели.

Метрики

MAE: 976598.44 руб.

MAPE: 6.68%



ГИПОТЕЗА ПОДТВЕРДИЛАСЬ

1. Модель явно включает тренд (полиномиальный) и сезонность (фичи месяцев), что соответствует структуре данных.
2. Коэффициенты модели (например, веса месяцев) позволяют анализировать вклад сезонности и получить прямую формулу расчета результата.

ЛЕГКИЕ РЕГРЕССИИ

Мы предположили, что модель, учитывающая особенности временного ряда (регрессия с сезонными фичами и полиномиальным трендом), даст более точный прогноз по сравнению с простыми моделями без учета сезонности или более сложными архитектурами.

Предобработка



- 01 Выплаты агрегированы по месяцам. Для стабилизации дисперсии применено логарифмирование.
- 02 Выполнена аддитивная декомпозиция (тренд, сезонность, остатки) для анализа структуры данных.
- 03 Тренд рассчитан при помощи скользящей средней

Метрики

MAE: 3073138.02 руб.


MAPE: 2.53%

Test Ljung-Box, p-value: 0.28




Три прогноза кажутся стабильными и устойчивыми. В таком случае лучше отдать предпочтение самому "легкому" и интерпретируемому решению.

Comparison of Forecasts (All Historical Data + Last 12 Months of Predictions)



miro



ДЕРЕВО РЕШЕНИЙ - ТАРГЕТ

Как агрегировать по месяцам и что предсказывать? Можно разложить на компоненты!

Между годами резко изменяется количество уникальных услуг и объем выплат



Количество выплат



Средняя сумма выплат на клиента



Средняя выплата ведет себя очень нестабильно между годами, не наблюдается устойчивая сезонность.



Количество клиентов



Средняя сумма выплат на услугу



Происходит перелом в объеме клиентов и выплат, меняется тренд и там и там



Количество услуг



Средняя выплата




Общая сумма выплат за месяц

Вывод: несмотря на перемены в компонентах общей суммы выплат между годами - сама сумма выплат подчиняется строгой сезонности. В декомпозиции суммы на компоненты нет нужды, потому что они ведут себя непрогнозируемо.

Причина: сумма выплат это отражение общей ситуации на рынке, а декомпозиция напрямую зависит от внутренней организации и внутренних решений бизнеса, поэтому ее компоненты могут резко менять свое поведение!

ДЕРЕВО РЕШЕНИЙ МОДЕЛИ



Мы предлагаем два подхода: один для работы при ограниченных данных, а второй для решения задач, если будут дополнительные данные

Линейная регрессия с трендом и сезонностью

Сильные стороны:

- 1 Быстрое обучение – эффективна на малом временном промежутке.
- 2 Простота реализации и интерпретируемость..
- 3 Гибкость – позволяет явно задавать тренд и сезонные компоненты

Слабые стороны:

- 1 Чувствительность к шумам – плохо обрабатывает нестационарность и автокорреляцию.
- 2 Ограниченность – требует настройки сезонных эффектов.

PROPHET

Сильные стороны:

- 1 Автоматически работает с трендом.
- 2 Автоматический учёт тренда и сезонности.
- 3 Лучше предсказывает сложные временные зависимости.

Слабые стороны:

- 1 Требуется больше данных – нужна выборка из нескольких лет.
- 2 Сложность настройки – подбор гиперпараметров требует большой отложенной выборки


Вывод:

- 01 Для текущей задачи (выборка за 2 года) – выбрана линейная регрессия с трендом и сезонностью.
- 02 В общем случае – Prophet предпочтительнее, так как лучше обрабатывает сложные временные зависимости.


QR на COLLAB




QR на GITHUB




В течение года наше решение можно превратить в полноценный production-ready сервис.
В формате диаграммы Ганта мы представили дорожную карту по интеграции решения.



Самое главное для митигации рисков - динамически дообучать модель на новых данных.
Дальнейшее обогащение данных позволит повысить точность.






ЯКИМОВ Роман
Product Manager

- 1. Формирование плана развития продукта
- 2. Создание roadmap
- 3. Проработка продуктовых гипотез



Сабанцева Саша
Project Manager/Designer

- 1. Создание визуализаций
- 2. Дизайн и структуризация материала
- 3. Управление планированием команды



ИГИТОВ Максим
MLE

- 1. Формирование гипотез по архитектуре модели
- 2. Обучение моделей
- 3. Тестирование и интерпретация моделей



ВИЧУК Артем
Product Analyst

- 1. Изучение рынка страховых продуктов
- 2. Изучение продуктовой логики Сбер страхования
- 3. Формулирование гипотез на базе рыночных инсайтов



БОГОДИСТ Сева
Data Scientist

- 1. Проведение разведочного анализа данных
- 2. Формулирование гипотез по моделям на базе данных
- 3. Обучение моделей сезонности и выявление трендов




Приложение. Агрегация по клиентам по месяцам.

Количество уникальных клиентов и средних выплат на клиента очень нестабильно в динамике по месяцам, не наблюдается сезонность



Приложение. Агрегация по выплатам по месяцам.

Количество выплат и их средний размер очень нестабильны в динамике по месяцам, не наблюдается сезонность



Приложение. Агрегация по услугам по месяцам.

Количество услуг и средний размер суммарных выплат по услугам очень нестабильны в динамике по месяцам, не наблюдается сезонность

